GeoEqui-LD 结构与训练对照实验

结果截至 2026 年 10 月 20 日 | 整理于 2026 年 10 月 22 日 | 结构、训练与 FH 定位

本阶段完成结构变体、训练信号、监督训练时长及 FH 目标宽度的首轮对照，并补充外部方法评价。几何一致性与伪监督联合配置相对匹配的纯监督续训，在两个 seed 中均降低 ALL 误差；完整结构在监督预热阶段的优势未延续至半监督终点；延长监督训练未消除训练与验证误差差距。

评价口径：旧报告使用既有 e39 训练状态，在 Testing501 评价。本轮结构对照从每个 seed 的共同未训练起点（cold）分别训练，在 Validation100 开发集评价；两者训练来源与评价集不同，不作直接数值比较。原 V2 监督、尺度与状态修订另列说明。

1 结构消融

结构	PSR / px	PSL / px	FHT / px	ALL / px	AoP / °
完整模型	13.877	17.867	38.877	23.541	8.113
去 PS 增强	13.921	18.339	37.823	23.361	8.454
去 FH 增强	14.883	17.542	38.848	23.758	8.508
无增强·独立头	14.184	17.581	38.172	23.312	8.412
无增强·共享头	13.673	16.517	37.228	22.473	7.105

表中为两个预定 seed 的半监督终点均值。每种结构分别进行 9000 步监督预热及 3000 步完整辅助训练，训练预算一致，不继承旧 e39 状态。逐 seed 结果、预热终点及尾部误差见补充结果表。

监督预热终点，FULL 的 ALL 在两个 seed 中均低于其余四种结构，均值为 25.825 px，共享简化结构为 32.176 px。半监督终点，共享简化结构的 ALL 与 AoP 在两个 seed 中均低于 FULL，表明监督预热阶段的相对优势未延续到半监督终点。

在无增强背景下，共享头较独立头在两个 seed 的 ALL、FHT 及 AoP 均较低。去除 PS 或 FH 增强相对 FULL 的 ALL 变化方向随 seed 不同。整块结构消融同时改变容量、残差连接与归一化，尚不能据此确定单个算子的独立贡献。

2 几何一致性与伪监督

训练信号	PSR / px	PSL / px	FHT / px	ALL / px	AoP / °
S	17.385	21.190	54.276	30.950	11.121
SG	14.662	18.658	43.568	25.630	8.943
SP	14.542	22.222	40.945	25.903	10.516
SGP	13.877	17.867	38.877	23.541	8.113

S 为医生标签监督，G 为几何一致性损失，P 为教师伪监督。每个 seed 从同一 FULL 预热状态分出 S、SG、SP 和 SGP 四条 3000 步续训，采用固定终点 student、普通 DSNT 及同一 Validation100。SP 仍使用几何置信筛选。

SGP 相对匹配 S 的 ALL 在两个 seed 中分别降低 11.909 和 2.911 px；SGP 相对 SP 分别降低 1.712 和 3.014 px，AoP 也均降低。单独引入 G 或 P 时，ALL 变化方向随 seed 不同，当前结果仅支持该训练配置下的组合收益。

SP 轨迹中，FH 热图筛选通过率约为 87%—89%，最终接受率约为 16%—17%。该统计反映筛选覆盖情况，不能代表伪标签准确率；现有结果也不足以将接受率较低单独归因于热图阈值。

3 监督训练时长对照

两个 FULL 模型由 60 遍续训至 300 遍，新增阶段采用余弦学习率。固定 300 遍终点的 Training300 ALL 分别约为 0.065 和 0.090 px，Validation100 为 52.052 和 45.730 px。延长训练未消除训练与验证误差差距，有限 BN 交叉诊断也未改善这一现象；该终点不代表充分调优后的监督性能上限。

4 FH 目标宽度复验

仅将医生 FH 目标宽度由σ4 调整为σ8，PS 仍为σ4。既有两 seed 探索中，ALL 平均降低 1.577 px；随后使用两个新 seed 进行同期复验。表中为复验的σ8−σ4 差值，负值表示误差降低。

复验差值	PSR / px	PSL / px	FHT / px	ALL / px	AoP / °
两 seed 均值	+1.689	+1.267	-2.753	+0.068	+0.329

复验中，两个 seed 的 FHT 误差均降低，PSR 与 PSL 均增加，ALL 变化方向不一致。FH 部分尾部误差的下降同时伴随其他误差区间的变化，尚不足以支持σ8 具有稳定的整体收益。

5 外部方法参照

方法（两 seed 均值）	PSR / px	PSL / px	FHT / px	ALL / px	AoP / °
STLD	11.229	16.823	25.646	17.900	5.767
PIPNet-GSSL	15.931	21.616	29.869	22.472	8.079

STLD 与 PIPNet-GSSL 均采用 ImageNet 预训练 R18，在 L300/U6000、B4 条件下进行三点任务资源适配，主终点分别为 STLD R4 和 PIP G5。方法间头、损失、训练量及读出不同，未构成严格等资源比较。ALL 样本 SD 分别为 1.161 和 2.105 px（n=2，非 CI）。PIP 为 2021 年方法，近期医学方法参照尚不充分。

在当前开发集口径下，STLD 的 ALL 与 AoP 两 seed 均值分别为 17.900 px 和 5.767°。课程相对监督起点的改善幅度随 seed 变化，起止差值不能单独解释为无标签数据的净效应。两个短预算 R18 初始化配对中，ImageNet 端五指标均低于随机端，ALL 平均差为−3.055 px；该结果仅适用于当前 R18 配方，不能直接解释 Geo HRNet 的训练与泛化表现。

6 后续工作

Geo 纯监督训练中的训练与验证误差差距尚未得到解释。编码器初始化是待检验因素之一；拟在核对同架构预训练权重、输入通道映射及 BN 适配后，比较随机初始化与预训练初始化。该对照保持结构、监督损失、普通 DSNT 读出、数据和训练预算一致，不同时调整 G/P、σ或分支，目前尚未执行。

当前结论限于上述首轮对照，已提供 CDF 聚合结果。四种独立方法的完整热图比较、基于真实 spacing 的毫米 SDR、少标签效率及鲁棒性验证尚不齐备。Validation100 已多次用于开发，不能作为独立患者或跨设备验证。

表中误差均越低越好。两 seed 均值不代表统计显著性，样本 SD 不是置信区间；本轮未新增 Testing 或 bootstrap。逐 seed 五指标、训练集结果、预热终点、尾部误差与实验协议见 GitHub；旧 Testing 主表单独保留。

完整结果与公开源码 https://github.com/heixuan-vsmenghu/GeoEqui-LD