GeoEqui-LD 阶段研究进展

结果截至 2026 年 10 月 20 日 | 整理于 2026 年 10 月 22 日 | 结构、训练与 FH 定位

围绕上一轮讨论的问题，本轮完成了结构、训练信号和 FH 目标宽度的首轮对照，并补充长监督诊断。当前证据支持几何与伪监督组合的条件性收益，但结构优势未稳定保持，延长监督训练也未解决泛化分化；我想继续弄清基础训练中这一分化的原因。外部方法仅作参照。

与上次结果的关系：旧报告来自既有 e39 训练状态与 Testing501。本轮为公平比较结构，另从共同未训练起点（cold）分别训练，并在 Validation100 开发集评价；不是对旧模型同口径复测，也不是旧成绩被新结果覆盖。V2 的监督、尺度和状态修订继续保留说明。

1 结构消融

结构	PSR / px	PSL / px	FHT / px	ALL / px	AoP / °
完整模型	13.877	17.867	38.877	23.541	8.113
去 PS 增强	13.921	18.339	37.823	23.361	8.454
去 FH 增强	14.883	17.542	38.848	23.758	8.508
无增强·独立头	14.184	17.581	38.172	23.312	8.412
无增强·共享头	13.673	16.517	37.228	22.473	7.105

表为两个预定 seed 的半监督末轮均值。每种结构从各自的 9000 步监督预热继续 3000 步完整辅助训练；同预算，不从旧 e39 继承。每个 seed、预热终点和尾部均保留在附录。

预热阶段，完整模型的 ALL 在两个 seed 都低于其余四种；其两 seed 均值为 25.825 px，共享简化结构为 32.176 px。但半监督末轮，共享简化结构的 ALL 和 AoP 在两个 seed 均低于完整模型，优势发生了变化。

无增强的共享头对独立头，是更直接的共享方式对照：末轮共享头的 ALL、FH、AoP 在两个 seed 均较低。去 PS 或去 FH 相对完整模型的 ALL 方向则有 seed 差异。现有证据不支持“每个增强块都稳定获益”；整块移除还涉及容量、残差和归一化，不能归因到单个算子。

2 几何一致性与伪监督

训练信号	PSR / px	PSL / px	FHT / px	ALL / px	AoP / °
S	17.385	21.190	54.276	30.950	11.121
SG	14.662	18.658	43.568	25.630	8.943
SP	14.542	22.222	40.945	25.903	10.516
SGP	13.877	17.867	38.877	23.541	8.113

S=医生标签监督；G=几何一致性损失；P=教师伪监督。两个 seed 从同一 FULL 预热状态各自分出四条 3000 步续训；固定末轮 student、普通 DSNT、同一 Validation100。SP 仍保留几何置信筛选。

完整 SGP 相对匹配 S，ALL 在两个 seed 分别降低 11.909 / 2.911 px；在 P 背景下加入 G，ALL 分别降低 1.712 / 3.014 px，AoP 也均降低。单加 G 或 P 的 ALL 方向仍有差异，因此支持的是当前条件下的组合收益，而不是每个模块普遍有效。

SP 轨迹中，FH 热图门通过约 87%—89%，最终接受约 16%—17%，不能只把问题归因于热图阈值过高。覆盖率不等于伪标签准确率，也不是删除几何门的依据。

3 长监督训练与泛化

两个 FULL 从 60 遍续训至 300 遍，新增部分使用余弦学习率。Training300 的 ALL 降至约 0.065 / 0.090 px，Validation100 却为 52.052 / 45.730 px；有限 BN 交叉诊断没有恢复问题。已确认延长训练未解决训练与验证分化，不能把 300 遍固定末轮叫作基础最优上限。

4 FH 目标宽度复验

仅把医生 FH 目标宽度从σ4 改为σ8，PS 仍为σ4。旧两 seed 探索的 ALL 平均下降 1.577 px；随后两个新 seed 同期复验，得到下列差值（σ8−σ4，负值为改善）。

复验差值	PSR / px	PSL / px	FHT / px	ALL / px	AoP / °
两 seed 均值	+1.689	+1.267	-2.753	+0.068	+0.329

FH 在两个新 seed 都改善，但 PS 两点都变差，ALL 一降一升。部分 FH 尾部改善也伴随其他误差区间的代价。因此暂不把σ8 作为稳定整体升级，不继续扩大宽度搜索。

5 补充对口参照

方法（两 seed 均值）	PSR / px	PSL / px	FHT / px	ALL / px	AoP / °
STLD	11.229	16.823	25.646	17.900	5.767
PIPNet-GSSL	15.931	21.616	29.869	22.472	8.079

均为 ImageNet R18、L300/U6000、B4 三点资源适配；固定 STLD R4 / PIP G5。头、损失、训练量和读出不同，不作严格等资源排名。ALL 样本 SD 分别 1.161 / 2.105 px（n=2，非 CI）。PIP 为 2021 年方法，近期医学方法覆盖仍需补充评估。

现有开发口径下 STLD 表现较强，其监督起点已较好，后续课程改善幅度有 seed 差异；课程起止差不能全归给无标签收益。两个短预算 R18 初始化配对中，ImageNet 端五指标均较低，ALL 均差−3.055 px，提供基础配方线索，但尚不能外推为 Geo HRNet 的根因。

6 接下来想进一步核查的问题

目前我想先弄清 Geo 纯监督训练与验证误差分化的原因。R18 初始化配对提供了一条可能线索，但还不能据此外推到 HRNet。如沿这个方向继续排查，我打算先核对同架构预训练权重、输入通道及 BN 适配，明确协议后，在结构、监督损失、普通 DSNT 读出、数据和预算不变的条件下做纯监督配对，暂不同时改变 G/P、σ或分支。目前尚未执行，具体范围和安排留待进一步讨论。

本轮完成的是四个方向的首轮对照，不是四个机制都已证明。CDF 聚合已有；四种独立方法完整热图、真实 spacing 支持的毫米 SDR、干净少标签效率和鲁棒性仍缺。Validation100 已多次用于开发，不能等同于独立患者或跨设备验证。

表中误差均越低越好。两个 seed 均值不代表统计显著性；未新增 Testing 或 bootstrap。完整逐 seed 五指标、训练集、预热终点、尾部与方法身份见 GitHub 结果页；旧 Testing 主表单独保留。

完整结果与公开源码 https://github.com/heixuan-vsmenghu/GeoEqui-LD